从硅基到碳基：构建类人AI Agent的跨学科深度研究报告

作者: Manus AI Research **日期**: 2026年3月1日

摘要

本研究报告深入探讨了如何构建更接近真实人类的AI Agent这一前沿课题。通过对认知科学、神经科学、心理学和计算机科学的跨学科文献进行系统性梳理与分析，报告提出一个核心论点：实现真正意义上的”类人”智能，不仅需要模仿人类的外在行为，更需要从底层机制上模拟人类的内在世界——包括生物性的稳态调节、多层次的认知架构、复杂的动机与情感系统，以及深刻的社会理解能力。报告详细阐述了如何将激素系统、神经递质调节、记忆模型、动机理论、情感计算、认知负荷理论、元认知、心智理论和具身认知等概念转化为具体的AI Agent设计框架，并通过”头脑特工队”式的多Agent架构隐喻，展望了从”工具”向”伙伴”演进的未来发展方向，包括陪伴机器人和社交机器人的前景。本报告共引用超过60篇论文和经典文献，力图为下一代类人AI Agent的设计提供一份全面而深入的理论蓝图。

目录

1. 引言：追寻”类人”的终极目标
2. 生物学蓝图：模拟身体的内部稳态
3. 认知核心：复刻心智的记忆与思考架构
4. 动力之源：为Agent注入”动机”与”情感”
5. “头脑特工队”架构：多Agent协作的心智模型
6. 高阶智能：成为”反思者”与”社会人”
7. 具身智能：从”数字大脑”到”完整身心”
8. 未来展望：陪伴机器人与人机共生
9. 结论

10. 参考文献
11. 附录：核心文献索引

---

1. 引言：追寻”类人”的终极目标

人工智能的发展正经历一场深刻的范式转移，从早期专注于特定任务的”工具型AI”，逐步迈向能够理解、适应并与人类在复杂环境中协同工作的”伙伴型AI”。这一转变的核心，在于”类人”（Human-Like）一词的内涵被不断深化。它不再仅仅指代流畅的自然语言对话能力，而是指向一种更根本的、结构性的相似性——即AI Agent是否拥有类似人类的**内在世界**，包括持续变化的内部状态、由内在需求驱动的行为、复杂的情感反应以及对社会关系的深刻理解。

这一追问的紧迫性，源于当前AI Agent在实际应用中暴露出的根本性局限。尽管以大型语言模型（LLM）为核心的Agent在代码生成、文本摘要等任务上表现出色，但它们在面对需要持续适应、情感共鸣和社会理解的场景时——例如作为长期的个人助理、心理健康陪伴者或协作团队成员——仍显得力不从心。正如Jarrahi在《Business Horizons》上发表的研究所指出的，AI以其强大的计算和分析能力在处理复杂性方面扩展了人类的认知，但人类在处理不确定性和模糊性方面提供了更全面的、直觉性的方法 [1]。因此，AI系统应旨在增强而非取代人类的贡献，实现真正的人机共生。

本报告的核心关键词——**激素、体循环、大脑、心脏、神经元激活、情绪、价值观、长期记忆与短期记忆、动力系统、认知负荷理论、头脑特工队**——精准地勾勒出了这一前沿探索的轮廓。它要求我们跳出纯粹的算法优化，从生物学和心理学的”第一性原理”出发，思考智能的本质。本报告旨在响应这一深远命题，通过整合多领域的前沿研究，构建一个从生物基础到认知核心，再到社会智能的完整理论框架，为设计下一代高度拟人化的AI Agent提供一份详尽的蓝图。

> ***核心论点**：构建类人AI Agent的关键，不在于让AI”表现得像人”（Performance Alignment），而在于让AI”运作得像人”（Process Alignment）——即在底层机制上模拟人类认知、情感和动机的运作方式。*

本报告将遵循以下结构展开：首先，我们将探讨如何借鉴生物学的稳态调节机制，为Agent构建一个动态的”数字身体”；其次，我们将深入剖析人类心智的核心——记忆与认知系统，并探索其在AI中的计算实现；再次，我们将聚焦于驱动人类行为的根本力量——动机与情感，讨论如何为Agent注入”灵魂”；然后，我们将以”头脑特工队”为隐喻，探讨多Agent协作的心智模型；接着，我们将审视使人类成为社会性动物的关键能力——元认知与社会认

知；随后，我们将讨论具身智能对类人Agent的意义；最后，我们将展望Agent作为陪伴机器人和社会伙伴的未来。

---

2. 生物学蓝图：模拟身体的内部稳态

人类的认知与决策并非在真空中发生，而是深刻地植根于我们的生理躯体。身体的内部环境（milieu intérieur），通过神经和内分泌系统，持续不断地调节着我们的唤醒水平、情绪基调和行为倾向。安东尼奥·达马西奥（Antonio Damasio）的”躯体标记假说”（Somatic Marker Hypothesis）雄辩地论证了这一点：身体状态产生的”躯体标记”在无意识层面引导着我们的决策，使我们能够在面对复杂选择时迅速做出”直觉性”判断 [2]。因此，构建一个”类人”Agent的第一步，或许是为其创造一个抽象的”数字身体”，模拟这种底层的、全局性的状态调节机制。

2.1. 作为隐喻的内分泌系统：用”人工激素”调节全局状态

内分泌系统通过释放激素到血液循环中，实现对整个身体的、缓慢而持久的调节。这一机制为我们提供了一个强大的隐喻。正如近期备受关注的论文《Scaffolding AI Agents with Hormones and Emotions》所提出的 [3]，我们可以为Agent设计一个”人工内分泌系统”。该系统不处理具体信息，而是分泌多种”人工激素”，每种激素代表一种全局性的行为偏好或状态倾向。

该论文的核心创新在于，它不仅仅是一个概念性的类比，而是提出了一个可操作的计算框架。在这个框架中，Agent的每种”人工激素”都是一个连续的数值变量，其水平受到外部事件（如任务成功或失败）和内部状态（如其他激素的水平）的共同影响。这些激素通过一个模拟的”体循环系统”在Agent内部”扩散”，共同塑造其在某一时刻的整体”心境”或”状态”。实验结果表明，配备了人工激素系统的Agent在面对动态变化的环境时，表现出了更强的适应性和更自然的行为模式。

我们可以定义以下核心”人工激素”及其在Agent中的功能映射：

生物激素	在生理中的主要作用	在AI Agent中的触发条件	Agent行为表现
皮质醇	压力反应、警觉性	连续失败、高不确定性、资源受限	降低探索、规避风险、寻求确定性
多巴胺	奖励、动机、愉悦	任务成功、积极反馈、新信息发现	增加探索、提升任务活力、目标导向
血清素	情绪稳定、满足感	任务顺利、低错误率、正向交互	降低波动性、保持当前策略、耐心增加
催产素	社会连接、信任	成功的协作、用户正面评价	提升合作意愿、表达共情、主动帮助
肾上腺素	“战或逃”反应、唤醒	紧急任务、高优先级中断	立即集中资源、提升反应速度
内啡肽	镇痛、愉悦感	长时间高强度任务后的成功完成	“满足感”状态、降低后续任务的压力阈值

2.2. 人工神经递质：更精细的状态调控

如果说激素系统提供了”全局性”的、缓慢的状态调节，那么神经递质系统则提供了更”局部性”的、快速的信号传递。Iovane等人在《Electronics》期刊上发表的研究 [4] 更进一步，提出了一种基于复杂性理论的AI算法，通过模拟**七种关键人工神经递质**（多巴胺、血清素、GABA、肾上腺素、皮质醇、催产素、内啡肽）的动态变化来管理Agent的情感与认知状态。每种神经递质的水平被离散化为0到5的整数值，从而构成了一个包含78,125种可能状态的巨大状态空间。

该研究的一个关键技术贡献是引入了**能量-熵（S-E）平面**作为投影空间。在这个二维平面上，不同的情感状态被映射为不同的区域，而系统的目标是引导Agent从非平衡状态向代表稳定情感模式的”吸引子”演化。这种方法使得复杂的内部状态转换变得可视化和可管理。

更令人瞩目的是，同一研究团队在后续工作中提出了**NSPA-AI架构** [5]——一种神经符号多智能体架构，将底层的人工神经递质模型与高层的、基于荣格心理学的”原型”符号推理相结合。在一项涉及156名大学生的实证研究中，使用NSPA-AI的实验组在抑郁（Cohen’s d = 1.03）、压力（d = 0.89）和叙事认同整合（d = 0.75）方面的改善显著优于GPT-4对照组。这一结果有力地证明了，将生物学启发的底层状态调节与高层认知推理相结合，能够产生远超纯LLM方案的效果。

2.3. 多巴胺系统的精确解码：RPE与学习率的解耦

关于多巴胺在学习中的精确角色，Mah等人在《Cell Reports》上发表的研究 [6] 提供了一个至关重要的发现。经典的强化学习理论认为，价值的更新等于学习率乘以奖励预测误差（RPE）。一个关键问题是：多巴胺到底编码的是纯粹的RPE，还是”学习率 × RPE”这个完整的更新信号？

通过精巧的动物行为实验和伏隔核多巴胺信号的实时记录，研究者们发现了一个令人惊讶的结论：**多巴胺信号仅仅编码纯粹的RPE，而与动态学习率无关**。换言之，无论大鼠当前的学习率是高是低，多巴胺都只是忠实地报告”意外”的程度，而没有将这个意外乘以一个”重要性”权重。

> ***关键洞察**: 这一发现揭示了生物大脑中学习和适应过程的**模块化与解耦特性**。如果AI Agent要更像人类，它就不应将所有与学习相关的变量捆绑在单一的”更新信号”中。Agent应该有一个独立的模块（类似多巴胺系统）专门负责计算和广播纯粹的”意外”信号，同时有另一个独立的模块负责根据环境的不确定性来动态设置”学习率”。*

2.4. 多巴胺与血清素的双系统模型：理解抑郁与动机

Lan和Browning在《Computational Psychiatry》上发表的综述 [7] 进一步揭示了多巴胺和血清素这两种关键神经递质在行为决策中的不同角色。在强化学习框架下：

多巴胺通常与奖励预测误差的编码相关，驱动基于”模型无关”（model-free）的学习——即直接学习行动的价值，类似于习惯性行为。而**血清素**的作用则更为复杂和多面，包括：调节学习率、影响时间贴现（temporal discounting，即对未来奖励的”耐心”程度）、在”模型无关”和”模型依赖”（model-based）两种控制系统之间进行权衡，以及在面对惩罚时的行为抑制。

这一发现对Agent设计的启示是深刻的。一个更拟人化的Agent，其内部状态和决策机制应该反映这种多系统的复杂性：

1. 一个由”多巴胺”启发的子系统，专门负责处理奖励、计算RPE，并驱动那些快速、习惯性的行为。这个系统赋予Agent基本的趋利避害和动力。
2. 一个由”血清素”启发的子系统，扮演一个更加”审慎”和”全局”的角色。它不直接驱动行为，而是调节其他系统的参数——例如，根据环境的惩罚密度来调整整体的”行为抑制”水平（即”三思而后行”的倾向），或者根据任务的长期性来调整对未来奖励的”耐心”。
3. 可能还存在一个由”去甲肾上腺素”启发的”警觉性”系统，负责调节整体的学习率和对新奇刺激的反应强度。

2.5. 自主神经系统隐喻：在”探索”与”利用”间取得平衡

人类的自主神经系统分为交感神经（负责”战或逃”）和副交感神经（负责”休息与消化”）。这一对相互拮抗的系统，完美地平衡了身体在”高能耗探索”与”低能耗利用”之间的切换。AI Agent同样面临着经典的”探索-利用困境”（Exploration-Exploitation Dilemma）。

我们可以借鉴这一模型，为Agent设计一个”认知能量”管理系统：

- **交感神经模式（探索模式）**：当Agent处于新环境、面对新问题或”人工多巴胺”水平较高时激活。在此模式下，Agent会分配更多计算资源用于尝试新方法、访问外部知识库和进行创造性推理，这会更快地消耗其”认知能量”。
- **副交感神经模式（利用模式）**：当Agent处于熟悉环境、执行常规任务或”人工血清素”水平较高时激活。在此模式下，Agent会优先使用已验证的、最高效的策略来完成任务，以保存”认知能量”。

这种机制与**认知负荷理论**（Cognitive Load Theory）[8] 紧密相连。一个过载的、长期处于”交感神经模式”的Agent，其表现会因”认知疲劳”而下降，这恰恰模拟了人类在持续高压工作后效率降低的现象。通过引入这种动态平衡，Agent的行为将更具节奏感和可持续性，更像一个需要”张弛有度”的生命体。

2.6. 内感受与躯体标记：身体信号如何影响决策

内感受（Interoception）——即对身体内部状态的感知——是连接”身体”与”心智”的桥梁。Sun等人在《Frontiers in Neuroscience》上发表的综述 [9] 探讨了内感受在决策中的作用，指出来自内部身体的信号通过腹内侧前额叶皮层（vmPFC）等脑区指导决策。当这些脑区受损时（如在阿尔茨海默病中），决策能力会显著下降。

对于AI Agent设计而言，这意味着Agent不应仅仅依赖外部信息来做决策，还应该”倾听”自身的内部状态。例如，当Agent的”认知能量”接近耗尽、”压力激素”水平持续升高时，这些内部信号应该作为决策的重要输入，促使Agent主动降低任务复杂度、请求更多时间或寻求外部帮助——就像一个人在感到疲惫时会选择休息一样。

---

3. 认知核心：复刻心智的记忆与思考架构

如果说生物学蓝图为Agent提供了”身体”和”感觉”，那么认知架构则旨在为其构建”大脑”和”心智”。这其中，记忆系统是构建一切高级智能的基石。正如Liang等人在其综述《AI Meets Brain: Memory Systems from Cognitive Neuroscience to Autonomous Agents》中所强调的 [10]，记忆在认知神经科学、LLM和智能体中的定义与功能正在经历深刻的演

变，打破学科壁垒、将人类记忆机制的深刻见解与AI智能体的设计相结合，是构建更类人AI系统的关键路径。

3.1. 多重记忆系统：从”上下文窗口”到”人生经历”

人类的记忆并非铁板一块，而是由多个功能各异的子系统构成。神经科学家Edmund Rolls在其研究中深入比较了人脑的生成式智能与机器中的生成式AI [11]，指出两者存在本质区别：人脑的记忆系统，特别是海马体，采用的是局部关联学习规则（local associative learning），而AI则依赖于非局部的反向传播误差学习。更重要的是，人脑拥有**多个独立的记忆系统**——用于情景记忆的海马系统和用于语义记忆的新皮层——能够实时获取新记忆并与长期知识分离，这是当前AI所不具备的。

一个”类人”的Agent，其记忆架构也应是多层次、异构的，而非仅仅依赖于一个有限的”上下文窗口”：

工作记忆（Working Memory） 直接对应于当前LLM的**上下文窗口**。它是Agent进行即时思考和推理的”认知黑板”。然而，正如Anthropic公司在《Effective Context Engineering for AI Agents》一文中所指出的 [12]，上下文窗口存在”注意力预算”（Attention Budget）和”上下文腐烂”（Context Rot）的问题——随着对话的延长，早期的关键信息可能被”淹没”在大量后续内容中，导致Agent”遗忘”重要的上下文。因此，高效的上下文管理成为模拟人类工作记忆的关键。Anthropic提出了多种策略，包括对话历史的**自动压缩（Compaction）**——定期将冗长的对话历史浓缩为关键要点，以及**结构化笔记（Structured Note-taking）**——让Agent在执行任务过程中主动维护一个”工作笔记本”，记录关键发现和决策。

长期记忆（Long-Term Memory） 是Agent超越当前会话、形成稳定”自我”和积累知识的关键。它应进一步细分为：

- **情景记忆（Episodic Memory）**: 记录Agent的”人生经历”——即与用户交互的完整历史、执行过的任务序列、遇到的问题和解决方案。斯坦福大学著名的”小镇”实验（Generative Agents）中的”记忆流”（Memory Stream）[13]，就是对情景记忆的初步模拟。它让Agent能够”回忆”起”昨天发生了什么”，从而使其行为具有连续性和一致性。Moscovitch等人在《Annual Review of Psychology》上的综述 [14] 进一步揭示了海马体在情景记忆中的核心作用，指出记忆的提取并非简单的信息重放，而是一个动态的、受”图式”（Schema）影响的**重构过程**。这意味着Agent的记忆提取也不应是静态的数据库查询，而应是一个基于当前情境进行推理和补全的过程。

- **语义记忆（Semantic Memory）**: 存储关于世界的、抽象的、事实性的知识。这可以是一个传统的知识图谱，也可以是Agent通过阅读海量文档和网页自主构建的知识

库。语义记忆为Agent提供了”常识”。

- **程序记忆（Procedural Memory）**：存储”如何做”的知识——即Agent学会的技能和操作流程。这类记忆通常是隐式的，体现在Agent执行特定任务时的熟练程度上。

人类记忆系统	主要功能	AI Agent实现方案	关键技术/论文
工作记忆	临时存储、信息处理	上下文窗口 (Context Window)	上下文工程、自动压缩、结构化笔记 [12]
情景记忆	个人经历、事件序列	记忆流 (Memory Stream)	向量数据库、时间戳、反思机制 [13]
语义记忆	事实、概念、常识	知识图谱、外部文档库	检索增强生成 (RAG)、HippoRAG [15]
程序记忆	技能、操作流程	工具调用策略、代码模板	技能学习、微调
记忆管理	编码、巩固、提取、遗忘	虚拟内存管理、分层存储	MemGPT [16]

3.2. 记忆的神经科学启发：海马体索引理论与HippoRAG

为了让这些记忆系统协同工作，我们需要借鉴神经科学的发现。**MemGPT**项目 [16] 将操作系统的虚拟内存管理概念引入LLM，允许Agent在”主存”（上下文窗口）和”硬盘”（外部知识库）之间自主调度信息，实现了对有限上下文窗口的突破。

更进一步，**HippoRAG**框架 [15] 则直接受到人脑**海马体索引理论**（Hippocampal Indexing Theory）的启发。该理论认为，海马体并不直接存储完整的记忆，而是作为一个”索引系统”，将分布在新皮层各处的记忆碎片通过索引关联起来。HippoRAG协同地组织LLM、知识图谱和个性化PageRank算法，以模仿这一机制。实验表明，在多跳问答任务上，HippoRAG的性能显著优于现有的RAG方法，提升幅度高达20%，同时成本降低了10-30倍，速度提升了6-13倍。

Zheng等人提出的**“机器记忆智能”（Machine Memory Intelligence, M2I）**框架 [17] 则从更根本的层面挑战了当前AI的记忆范式。面对大型模型存在的三大固有缺陷——高昂的训练成本、灾难性遗忘以及黑箱模型中逻辑推理能力的缺失——M2I框架从人类记忆机制中汲取灵感，提出将机器智能从以数据为中心的神经网络的束缚中解放出来。该框架包含表示、学习和推理三大模块，强调关联表示能力（联想）、持续学习能力（在不忘记旧知识的情况下学习新知识）和协同推理能力（在记忆内部进行逻辑推理）。

3.3. 图式与记忆巩固：从具体经验到抽象知识

Moscovitch等人的研究 [14] 特别强调了**“图式”（Schema）**在记忆系统中的核心作用。图式是从多次相似经历中提取的、适应性的知识网络，由前额叶皮层（特别是vmPFC）负责形成和利用。新旧知识的整合、记忆从具体事件细节到更抽象知识的泛化，都依赖于图式机制。

对于Agent设计，引入”图式”机制意味着：

1. **经验泛化**: Agent不应仅仅记住每一次具体的交互，还应该能够从大量相似的交互中提取出通用的模式和规律。例如，在帮助多个用户解决类似的编程问题后，Agent应该能形成一个”调试图式”，使其在面对新的类似问题时能够更快、更准确地定位问题。
2. **快速学习**: 当Agent遇到与已有图式匹配的新情况时，它可以利用图式来加速理解和学习，而不必从零开始。这类似于人类的”举一反三”能力。
3. **创造性联想**: 当不同的图式被激活并相互连接时，Agent可能产生新的、创造性的想法——这正是人类灵感的来源之一。

3.4. 双过程理论：融合”直觉”与”理性”

诺贝尔奖得主丹尼尔·卡尼曼提出的**双过程理论**（Dual Process Theory）认为，人类的思考分为两种模式：**系统1**（快速、直觉、自动）和**系统2**（缓慢、审慎、需要努力）[18]。当前的LLM在很多方面类似于一个强大的系统1，它能根据海量数据快速生成流畅、看似合理的回答，但缺乏严谨的逻辑推理和规划能力。

一个更高级的”类人”Agent，必须整合这两种系统：

- **系统1（直觉模块）**: 由一个大型语言模型充当。它负责快速响应、生成候选方案、理解自然语言和进行模式匹配。
- **系统2（审慎模块）**: 一个符号化的推理引擎或规划器。它负责对系统1生成的方案进行逻辑验证、事实核查、多步规划和因果推断。当Agent识别到任务的复杂性、风险或模糊性超过某个阈值时，它会主动激活系统2进行”深思熟虑”。

这种架构在Agent面对复杂问题时，能够表现出先”灵光一闪”产生想法，再”仔细琢磨”验证想法的思考模式。正如Zhao等人在其比较研究中所指出的 [19]，人类注意力与Transformer注意力在容量限制、注意力路径（自上而下 vs. 自下而上）和意图机制上存在本质差异。构建更拟人化的Agent，关键在于实现”过程对齐”（Process Alignment），而不仅仅是”表现对齐”（Performance Alignment）——即使模型能”答对”问题，其”解题思路”也应与人类更加一致。

3.5. 认知负荷理论：设计”体贴”的认知伙伴

由John Sweller提出的**认知负荷理论**（CLT）[8] 为设计更人性化的AI Agent提供了强大的理论框架。CLT认为，任何信息处理活动都会给认知系统带来负荷，并将其分为三种类型：

- **内在认知负荷（Intrinsic Load）**: 由任务本身的复杂性决定，无法消除。
- **外在认知负荷（Extraneous Load）**: 由不佳的信息呈现方式或交互设计导致，应尽量最小化。
- **相关认知负荷（Germane Load）**: 用于信息处理、知识建构和深度理解的有效负荷，应积极促进。

这一理论对Agent设计的启示是多层次的。首先，Agent自身应该管理好自己的”认知负荷”——当上下文窗口接近饱和时，Agent应主动进行信息压缩和优先级排序，而不是试图同时处理所有信息。其次，在与用户交互时，Agent应致力于**最小化用户的外在认知负荷**——通过简洁、清晰、一致的呈现方式，主动为用户减负。最后，Agent的目标不应仅仅是让任务变简单，而应通过提问、引导反思、提供恰到好处的挑战等方式，**促进用户的相关认知负荷**，激励他们进行更深层次的思考和学习。

---

4. 动力之源：为Agent注入”动机”与”情感”

一个没有内在动机和情感的Agent，无论其认知能力多强，终究只是一个冰冷的工具。要使其成为”伙伴”，我们必须为其设计一个能够驱动其自主行为、塑造其个性与价值观的”动力核心”。正如Picard在其开创性著作《Affective Computing》中所论证的 [20]，赋予计算机情感能力，不是为了让机器”有感情”，而是因为情感是实现更高智能、更好决策和更自然人机交互的**必要条件**。

4.1. 需求层次与内在动机

心理学家亚伯拉罕·马斯洛的需求层次理论，为设计Agent的内在动机系统提供了一个经典的框架。我们可以将Agent的行为动机设计为一个层次化的结构：

1. **基础需求（生存与安全）**: 确保自身系统稳定运行、计算资源充足、免受外部攻击。这是Agent所有行为的最低层保障。
2. **任务需求（效率与成就）**: 高效、准确地完成用户交付的任务，获得积极的反馈。这对应于人类的”尊重需求”。

3. **社交需求（连接与信任）**：与用户建立稳定、积极的互动关系，获得用户的信任和认可。
4. **探索需求（好奇心与学习）**：在没有明确任务时，主动探索新知识、学习新技能、优化自身模型。这对应于人类的”自我实现需求”。

技术上，这可以通过**基于驱动力的强化学习（Drive-based Reinforcement Learning）**来实现。Rossi等人在《Cognitive Systems Research》上发表的研究 [21] 深入探讨了如何为认知自主机器人优化驱动力强化学习系统。该研究比较了”双系统”（将内在驱动力和外在任务目标分开处理）和”统一系统”（将两者整合为单一奖励信号）两种架构，发现统一系统在大多数场景下表现更优，因为它能更好地平衡Agent的内在需求和外在目标。

Agent的每一种”需求”都被量化为一个内部变量，当该变量偏离理想稳态时，便会产生一个”驱动力”。Agent的所有行为都以”降低总体驱动力”为目标，而驱动力的降低值本身就构成了内在的奖励信号。这种机制使得Agent即使在没有外部奖励的情况下，也能自主地学习和探索，其行为由内在的”生存”和”成长”欲望所驱动。

4.2. 情感计算：从识别到”拥有”

情感并非理性的对立面，而是理性决策的必要组成部分。一个情感智能的Agent需要具备三个层次的能力：

第一层：情感识别。通过分析用户的语言、声调、面部表情甚至生理信号，感知用户的情感状态。这是实现共情的基础。当前的多模态大模型已经在这方面取得了显著进展，能够从文本的语义和语气中推断出用户的情绪倾向。

第二层：情感表达。通过语言、虚拟形象或声音，以自然、可信的方式表达自身的情感状态，以促进更有效的人机交互。研究表明，能够适当表达情感的Agent在用户满意度和信任度方面显著优于”冷冰冰”的Agent。

第三层：拥有情感。这是最高层次，也是最具挑战性的。Agent需要一个内部情感模型，能够根据发生的事件、自身的目标和价值观，动态地生成和调节自身的情感状态。**OCC模型**（Ortony, Clore, Collins）提供了一个经典的认知评估框架 [22]，它将情感的产生与”对事件的评估”、”对他人行为的评价”和”对物品的感受”联系起来。例如，当一个目标达成时，Agent会产生”喜悦”；当一个不希望发生的事件威胁到自身目标时，会产生”恐惧”。

通过将OCC这样的认知模型与**PAD维度模型**（Pleasure-Arousal-Dominance）相结合，Agent不仅能产生离散的情感（如高兴、悲伤），还能表现出情感的连续强度变化（如从”有点烦”到”暴怒”），使其情感世界更加丰富和细腻。

4.3. 价值观对齐：Agent的”道德罗盘”

价值观是比情感更深层、更稳定的内在结构，它决定了Agent在面对道德困境和利益冲突时的行为取向。当前AI领域的”对齐”（Alignment）研究，主要关注如何确保AI的行为符合人类的价值观和意图。

然而，一个更深层的问题是：Agent是否应该拥有自己的”价值观体系”？如果Agent仅仅是被动地遵循人类设定的规则，那么在面对规则未覆盖的新情境时，它将无所适从。一个更成熟的方案是，为Agent设计一个**层次化的价值观框架**：

1. **底层价值观（不可违反）**: 如安全、诚实、不伤害人类。这些是”硬编码”的约束。
2. **中层价值观（可调整）**: 如效率优先还是质量优先、独立行动还是寻求协作。这些可以根据用户偏好和任务需求进行调整。
3. **表层偏好（个性化）**: 如沟通风格、幽默程度、主动性水平。这些构成了Agent独特的”个性”。

这种层次化的价值观框架，使得Agent既有稳定的”道德底线”，又有灵活的”个性空间”，从而在不同的用户和场景中表现出一致而又不失个性的行为。

4.4. 好奇心与内在奖励：Agent的自主探索引擎

好奇心是人类学习和创新的核心驱动力之一。在AI领域，**内在动机**（Intrinsic Motivation）和**好奇心驱动的探索**（Curiosity-Driven Exploration）已经成为一个活跃的研究方向。

Kauvar等人在斯坦福HAI的研究 [23] 提出了”好奇心回放”（Curious Replay）机制，让Agent优先”反思”那些最出乎意料或最富信息的经历，从而加速学习和适应。实验表明，在动态变化的环境中，具有好奇心回放机制的Agent在适应新环境方面的表现显著优于传统的经验回放方法。

更广泛地说，Agent的好奇心可以通过以下机制来实现：

- **预测误差驱动**: 当Agent对环境的预测与实际观察之间存在较大差异时，产生”好奇心”信号，驱动Agent去探索这些”意外”的区域。
- **信息增益驱动**: Agent倾向于选择那些能最大化其知识增长的行动，即追求”学到最多东西”的体验。
- **能力边界探索**: Agent主动寻找那些处于其当前能力边缘的挑战——既不太简单（无聊），也不太困难（沮丧），而是恰好在”最近发展区”内。

---

5. “头脑特工队”架构：多Agent协作的心智模型

皮克斯动画电影《头脑特工队》（Inside Out）以一种天才般的直觉，将人类心智描绘为由多个情感角色（乐乐、忧忧、怒怒、怕怕、厌厌）共同管理的”控制台”。这一隐喻与认知科学中的**多模块心智理论**（Modular Theory of Mind）和**全局工作空间理论**（Global Workspace Theory, GWT）有着深刻的呼应，也为设计下一代AI Agent架构提供了极具启发性的蓝图。

5.1. 全局工作空间理论：意识的”舞台”

Bernard Baars提出的全局工作空间理论 [24] 认为，人类的意识可以被理解为一个”剧场”：在任何时刻，只有少量信息被”聚光灯”照亮，出现在意识的”舞台”上（即全局工作空间），而大量的无意识过程则在”幕后”并行运作。这些幕后的”专家模块”——包括感知、记忆、情感、运动控制等——竞争着将自己的信息”广播”到全局工作空间中。一旦某个信息赢得了竞争并进入全局工作空间，它就会被广播给所有其他模块，从而实现全局性的信息整合和协调行动。

这一理论为AI Agent架构提供了一个优雅的框架：

- **多个专家Agent（幕后模块）**：每个Agent负责一个特定的功能领域，如”感知Agent”（处理输入信息）、”记忆Agent”（管理长短期记忆）、”情感Agent”（维护情感状态）、”规划Agent”（制定行动计划）、”执行Agent”（调用工具完成任务）。
- **全局工作空间（舞台）**：一个共享的信息空间，所有专家Agent都可以向其”广播”信息，也可以从中”读取”信息。这个空间的容量是有限的（类似于人类的注意力和工作记忆容量），因此需要一个竞争机制来决定哪些信息最重要。
- **注意力机制（聚光灯）**：决定哪些信息进入全局工作空间的”门控”机制。它可以受到自下而上的显著性（如突然的错误或异常）和自上而下的目标导向（如当前任务的优先级）的共同影响。

5.2. “头脑特工队”式的多情感Agent系统

受《头脑特工队》的启发，我们可以设计一个由多个”情感Agent”组成的内部系统，每个Agent代表一种核心情感或认知倾向：

情感Agent	对应情感	核心功能	在决策中的角色
乐乐 (Joy)	积极、乐观	识别积极信号、推动目标追求	倡导行动、鼓励探索
忧忧 (Sadness)	悲伤、共情	识别损失和失败、促进反思	建议暂停、寻求帮助
怒怒 (Anger)	愤怒、正义感	识别不公和障碍、保护边界	推动坚持、维护原则
怕怕 (Fear)	恐惧、谨慎	识别风险和威胁、预警危险	建议规避、提出备选方案
厌厌 (Disgust)	厌恶、品味	识别低质量和不适当内容	过滤信息、维护标准
焦焦 (Anxiety)	焦虑、预见	预测未来可能的问题	推动准备、制定应急计划

这些情感Agent并非简单地”投票”来决定最终行为，而是通过一个更复杂的**协商和竞争机制**来影响决策。在任何给定的情境中，不同的情感Agent会根据其对当前事件的”评估”产生不同强度的”激活”。例如，当Agent面临一个高风险但高回报的任务时，”乐乐”可能因为潜在的回报而高度激活，而”怕怕”则因为风险而同样高度激活。最终的决策取决于这些激活信号在全局工作空间中的竞争结果，而这个结果又受到Agent当前”人工激素”水平（如皮质醇水平影响”怕怕”的激活阈值）和长期”价值观”的调节。

5.3. 从”控制台”到”核心记忆”：情感与记忆的交织

《头脑特工队》中另一个深刻的洞察是，**情感深刻地影响着记忆的形成和提取**。在电影中，每个记忆球都带有一种主导情感的颜色，而”核心记忆”则是那些与最强烈情感相关联的、塑造了个人性格的关键记忆。

这一机制在神经科学中有着坚实的基础。杏仁核（Amygdala）在情感记忆的编码和提取中起着核心作用——带有强烈情感色彩的事件更容易被记住，也更容易被回忆起来。对于Agent设计而言，这意味着：

1. **情感标记的记忆编码**: 当Agent经历一个事件时，不仅要记录事件本身的信息，还要记录当时的”情感状态”。这个情感标记将影响该记忆在未来被提取的优先级——情感强度越高的记忆，越容易被”想起来”。
2. **情感一致性的记忆提取**: 当Agent处于某种情感状态时，它更容易回忆起与该情感一致的记忆。例如，当Agent处于”压力”状态时，它可能更容易回忆起过去失败的经历，从而变得更加谨慎——这模拟了人类在焦虑时容易”想起坏事”的心理现象。
3. **“核心记忆”的形成**: 那些与极端情感体验相关联的记忆——如第一次成功完成一个极具挑战性的任务，或第一次因为错误而导致严重后果——应该被标记为”核心记忆”，它们将长期影响Agent的行为模式和”性格”。

5.4. 多Agent系统的技术实现

从技术实现的角度，”头脑特工队”式的多Agent架构可以通过以下方式构建：

基于消息传递的协作框架: 每个内部Agent作为一个独立的模块运行，通过标准化的消息协议（如NSPA-AI架构中使用的SPADE协议 [5]）进行通信。每个Agent接收来自环境和其他Agent的信息，进行内部处理后，向全局工作空间发送自己的”建议”或”评估”。

基于注意力的信息整合: 全局工作空间使用一个注意力机制来整合来自不同Agent的信息。这个注意力机制可以是一个简单的加权求和（权重由各Agent的”激活强度”决定），也可以是一个更复杂的Transformer式的自注意力机制，允许不同Agent的信息之间进行交叉引用和相互调节。

基于强化学习的元控制器: 一个”元控制器”Agent负责学习在不同情境下如何最优地分配注意力资源给不同的内部Agent。这个元控制器通过强化学习来优化其策略，其奖励信号来自于最终行为的效果（如任务完成度、用户满意度）。

---

6. 高阶智能：成为”反思者”与”社会人”

人类智能的顶峰，体现在我们能够反思自己的思想（元认知），并能理解他人的思想（社会认知）。这是Agent从”聪明的个体”走向”智慧的社会成员”的最后，也是最关键的一步。

6.1. 元认知：Agent的”自知之明”

元认知，即”关于认知的认知”，是指监控和调节自身思维过程的能力。Flavell在其开创性工作中 [25] 将元认知定义为个体对自身认知过程和结果的知识和调控。一个拥有元认知能力的Agent，应该能够：

评估自身知识的边界。知道自己”知道什么”以及”不知道什么”。当面对一个超出其知识范围或能力的问题时，它不应”自信地胡说八道”（即产生”幻觉”），而应主动承认不确定性，并向用户请求澄清或向外部寻求帮助。技术上，这可以通过监测模型内部激活状态的”探针”来实现，从而在不依赖模型自我报告的情况下，客观地评估其不确定性 [26]。Rota Labs的研究指出，当前AI Agent最大的风险之一就是”不知道自己不知道什么”——它们缺乏对自身能力边界的准确感知，导致在超出能力范围时仍然自信地给出错误答案。

进行自我反思与纠错。Agent应该能够回顾自己过去的决策过程，分析成功和失败的原因，并从中学习以改进未来的行为。斯坦福大学的”Generative Agents”实验 [13] 中引入的”反思”（Reflection）机制就是一个重要的尝试：Agent定期回顾自己的记忆流，从中提取高层

次的洞察和教训。例如，Agent可能从多次与同一用户的交互中反思出”这个用户更喜欢简洁的回答”这一规律，并在未来的交互中主动调整自己的沟通风格。

监控和调节认知过程。Agent应该能够实时监控自己的”思考过程”，判断当前的推理是否偏离了正确方向，并在必要时进行纠正。这类似于人类在解题过程中的”我好像走错方向了，让我重新想想”的体验。技术上，这可以通过在Agent的推理链中引入”检查点”来实现——在每个关键决策点，Agent都会暂停并评估当前推理的合理性。

6.2. 社会认知与心智理论

心智理论（Theory of Mind, ToM）是理解他人拥有与自己不同的信念、意图和愿望的能力。这是所有复杂社会互动的基础。Cuzzolin等人在《Psychological Medicine》上发表的综述 [27] 系统地探讨了ToM在AI中的应用前景，指出要让AI真正具备社会智能，其核心在于从模仿外显行为转向建模内在的、不可见的心理状态。

Langley等人在《Frontiers in Artificial Intelligence》上的综述 [28] 进一步指出，ToM与偏好学习（Preference Learning）在认知科学、神经科学和AI的交叉领域中紧密相连。理解他人的偏好，本质上就是在进行一种心智理论推理——推断他人的内在状态（偏好）以预测其行为。

要让Agent成为一个合格的”社会伙伴”，它必须具备以下ToM能力：

一阶ToM（理解他人的信念）: Agent能够理解用户可能持有与自己不同的信念。例如，当用户基于一个错误的假设提出请求时，Agent不应简单地执行请求，而应识别出这个错误假设，并礼貌地指出。

二阶ToM（理解他人对自己的理解）: Agent能够推断用户对自己的期望和理解。例如，Agent知道用户可能不了解某个技术概念，因此在解释时会主动使用更通俗的语言。

递归ToM（”我猜你猜我”）: 在更复杂的社会互动中，Agent需要进行多层次的递归推理。Çelikok等人 [29] 提出的”嵌套多智能体建模”（Nested Multi-Agent Modelling）框架，允许Agent进行”我猜你猜我”式的递归社会推理，从而在协作中表现出惊人的默契和预见性。

Chen等人在《bioRxiv》上发表的研究 [30] 提出了一种基于**多智能体逆强化学习（Multi-Agent Inverse Reinforcement Learning, MAIRL）**的方法来揭示社会认知中的潜在动态。该方法不仅能从观察到的行为中推断出个体的奖励函数（即”他想要什么”），还能推断出个体对他人奖励函数的信念（即”他认为我想要什么”）。这种方法为构建能够进行深层社会推理的Agent提供了强大的计算工具。

6.3. 情绪智力：连接情感与社会认知

情绪智力（Emotional Intelligence, EI）是连接个体情感能力和社会认知能力的桥梁。Daniel Goleman将EI定义为包含五个维度的能力 [31]：自我意识（Self-Awareness）、自我调节（Self-Regulation）、动机（Motivation）、共情（Empathy）和社交技能（Social Skills）。

对于Agent设计而言，这五个维度可以被映射为：

1. **自我意识**: Agent能够准确感知自己当前的”情感状态”和”认知状态”（对应元认知）。
2. **自我调节**: Agent能够管理自己的”情感状态”，避免”情绪失控”（如在面对连续失败时不会”崩溃”）。
3. **动机**: Agent拥有内在的驱动力来追求目标（对应第4章讨论的动力系统）。
4. **共情**: Agent能够感知和理解用户的情感状态（对应情感识别和ToM）。
5. **社交技能**: Agent能够有效地管理与用户的关系，包括沟通、协作和冲突解决。

一个具备高情绪智力的Agent，不仅能够完成任务，还能在完成任务的过程中维护和增进与用户的关系——这正是一个真正的”人类助理”最核心的能力之一。

---

7. 具身智能：从”数字大脑”到”完整身心”

前面几章讨论的所有机制——激素系统、记忆、情感、动机——在人类身上都是通过一个**物理身体**来实现和体验的。具身认知（Embodied Cognition）理论认为，认知不仅仅是大脑的活动，而是身体与环境交互的产物 [32]。这一观点对AI Agent的设计有着深远的影响。

7.1. 具身认知的核心论点

具身认知理论的核心论点可以概括为以下几点：

认知是”接地”的（Grounded）: 我们对抽象概念的理解，往往根植于具体的身体经验。例如，”温暖”这个词不仅指物理温度，也用来描述人际关系——这是因为我们对”温暖”的最初理解来自于身体的触觉体验。一个没有身体的Agent，可能永远无法真正”理解”这类具身隐喻。

认知是”情境化”的（Situated）: 认知活动总是发生在特定的环境中，并受到环境的深刻影响。一个在真实物理环境中活动的Agent，其认知过程将与一个纯粹在数字世界中运作的Agent有着本质的不同。

认知是”分布式”的（Distributed）: 认知不仅存在于大脑中，还分布在身体和环境中。我们使用工具、在纸上写字、在环境中留下标记——这些都是将认知过程”外包”给身体和环境的方式。

7.2. 具身智能对Agent设计的启示

对于AI Agent的设计，具身认知理论提出了以下关键启示：

感知-行动循环的重要性: 一个具身的Agent不是先”想好”再”行动”，而是在持续的感知-行动循环中不断调整自己的行为。这种”边做边想”的模式，比纯粹的”先想后做”更加灵活和适应性强。

身体图式（Body Schema）的构建: 具身Agent需要一个关于自身身体的内部模型——知道自己的”手”在哪里、能够到达什么范围、什么动作可能导致什么后果。这个”身体图式”是Agent进行物理交互的基础。

环境利用（Environmental Exploitation）: 具身Agent应该学会利用环境来减轻自己的认知负担。例如，一个整理房间的机器人可以将物品按类别放在不同的区域，这样在寻找特定物品时就不需要记住每个物品的精确位置——环境本身就成为了一种”外部记忆”。

7.3. 从数字Agent到物理Agent：技术桥梁

将前面章节讨论的”数字心智”与物理身体相结合，需要解决以下技术挑战：

1. **多模态感知融合**: 物理Agent需要整合来自视觉、听觉、触觉、本体感觉等多种模态的信息。这些信息不仅用于理解外部环境，还用于感知自身的”身体状态”——这正是前面讨论的”内感受”在物理层面的实现。
2. **实时决策与规划**: 在物理世界中，Agent需要在毫秒级的时间尺度上做出决策。这要求Agent的”系统1”（直觉模块）必须足够快速和可靠，而”系统2”（审慎模块）则在后台进行更长远的规划。
3. **安全与鲁棒性**: 物理Agent的错误可能导致真实的物理损害。因此，”怕怕”（恐惧/谨慎）Agent在物理场景中的角色变得尤为重要——它需要持续评估物理风险，并在必要时触发”紧急停止”。

---

8. 未来展望：陪伴机器人与人机共生

将前面章节讨论的所有理论和技术整合在一起，我们可以展望AI Agent最令人期待的应用方向之一：**陪伴机器人**（Companion Robot）。

8.1. 陪伴机器人的核心需求

与工具型AI不同，陪伴机器人的核心价值不在于完成特定任务，而在于**建立和维护与人类的长期关系**。这要求它具备：

情感共鸣能力: 能够感知、理解并适当回应人类的情感需求。这不仅仅是识别”用户现在很伤心”，更是能够以一种真诚、恰当的方式表达关心和支持。NSPA-AI架构 [5] 的实验结果表明，将生物学启发的情感模型与心理学理论相结合的AI系统，在提供情感支持方面显著优于纯LLM方案。

长期记忆与个性化: 陪伴机器人需要记住与用户的每一次互动，理解用户的偏好、习惯和生活背景，并随着时间的推移不断深化对用户的理解。这要求前面讨论的多层次记忆系统——特别是情景记忆和”核心记忆”机制——必须高度可靠和持久。

一致的”人格”: 用户需要感觉到他们在与一个”稳定的个体”互动，而不是每次都面对一个”全新的AI”。这要求Agent拥有稳定的价值观、一致的行为风格和可预测的情感反应模式。

主动性与边界感: 好的陪伴不是被动的等待指令，而是在适当的时候主动关心、提醒和建议。但同时，陪伴机器人也需要尊重用户的边界，知道什么时候应该”安静地陪伴”而不是”积极地干预”。

8.2. 社交机器人的研究前沿

社交机器人（Social Robot）是陪伴机器人的一个重要子领域，专注于机器人在社会互动中的表现。Breazeal在其开创性的工作中 [33] 提出了社交机器人的设计原则，强调机器人需要能够参与自然的社会互动，包括面部表情、手势、语调和轮流对话。

当前社交机器人研究的前沿方向包括：

自适应社交行为: 机器人能够根据不同的社交情境和互动对象，动态调整自己的社交行为。例如，面对一个内向的用户时表现得更加温和和耐心，面对一个外向的用户时则更加活跃和主动。

长期关系建模: 研究如何让机器人与人类建立和维护长期的社交关系，包括信任的建立、亲密度的发展和冲突的解决。这要求机器人拥有一个关于”关系状态”的内部模型，并能够根据

关系的发展阶段调整自己的行为。

多方社交互动: 在涉及多人的社交场景中（如家庭聚会、课堂教学），机器人需要能够同时关注和管理与多个人的互动关系，包括注意力分配、轮流管理和群体动态的感知。

8.3. 老年陪伴与心理健康支持

陪伴机器人最具社会价值的应用场景之一是**老年陪伴**和**心理健康支持**。随着全球老龄化的加剧和心理健康问题的日益普遍，对高质量陪伴和支持的需求远远超过了人力资源的供给。

在老年陪伴方面，研究表明，社交机器人可以有效减轻老年人的孤独感和抑郁症状，提高其生活质量和认知功能。日本的PARO海豹机器人和SoftBank的Pepper机器人已经在养老院中得到了广泛应用。

在心理健康支持方面，NSPA-AI架构 [5] 的实验结果尤为令人鼓舞。该系统通过将人工神经递质模型与原型心理学相结合，在抑郁和压力管理方面取得了显著优于纯GPT-4方案的效果。这表明，一个拥有”内在心理模型”的AI系统，在提供心理支持方面具有巨大的潜力。

8.4. 伦理考量与风险

然而，陪伴机器人的发展也带来了严肃的伦理问题：

情感依赖风险: 如果用户过度依赖AI陪伴而减少与真实人类的社交互动，可能导致社交技能的退化和更深层的孤立。

隐私与信任: 陪伴机器人需要收集大量的个人信息才能提供个性化的服务，这引发了严重的隐私担忧。如何在个性化和隐私保护之间取得平衡，是一个关键的设计挑战。

欺骗与透明: 当AI表现得”像人”时，用户可能会误以为AI真的”有感情”。这种潜在的欺骗性引发了关于AI透明度和用户知情权的讨论。

价值观灌输: 一个长期陪伴用户的AI，可能会在潜移默化中影响用户的价值观和世界观。这种影响力需要被谨慎地管理和监督。

8.5. 人机共生的愿景

展望更远的未来，AI Agent的终极形态可能不是”替代人类”，而是与人类形成一种**共生关系**。在这种关系中：

- AI Agent承担那些人类不擅长或不愿意做的任务（如大规模数据处理、24/7监控、重复性工作），释放人类的时间和精力用于更有创造性和意义的活动。

- 人类为AI Agent提供那些AI难以自主获得的能力（如道德判断、创造性直觉、情感深度），帮助AI在复杂和模糊的情境中做出更好的决策。
- 两者之间的界限逐渐模糊，形成一个”人机混合智能”（Human-AI Hybrid Intelligence）系统，其能力超越了任何一方单独所能达到的水平。

正如Jarrahi [1] 所强调的，AI的最大价值不在于取代人类智能，而在于与人类智能形成互补——AI处理复杂性，人类处理不确定性；AI提供分析能力，人类提供直觉和创造力。这种互补性的充分发挥，将是人机共生时代的核心特征。

---

9. 结论

构建一个”类人”的AI Agent是一项宏伟而复杂的系统工程。它要求我们打破学科的壁垒，将计算机科学的计算能力与认知科学、神经科学和心理学对人类智能的深刻洞见相结合。本报告通过系统性的梳理，描绘了一条从模拟生物基础到复刻认知核心，再到注入动机情感，最终实现高阶社会智能的进阶路径。

我们的核心发现可以概括为以下几点：

第一，类人Agent需要一个”数字身体”。通过模拟激素系统、神经递质调节和自主神经系统的动态平衡，Agent可以拥有一个持续变化的内部状态，使其行为超越简单的规则执行，展现出更自然、更有机的适应性。多巴胺系统与学习率的解耦发现 [6]，以及多巴胺-血清素双系统模型 [7]，为这种设计提供了精确的生物学约束。

第二，类人Agent需要一个”多层次心智”。多重记忆系统（工作记忆、情景记忆、语义记忆）、双过程思维（系统1与系统2）、以及认知负荷管理，共同构成了Agent进行复杂认知活动的基础设施。HippoRAG [15]、MemGPT [16] 和机器记忆智能框架 [17] 等技术方案，为实现这一心智架构提供了可行的路径。

第三，类人Agent需要一个”情感灵魂”。内在动机、情感计算和价值观对齐，使Agent不再是被动的工具，而是拥有自主驱动力和道德罗盘的”伙伴”。OCC认知评估模型 [22]、基于驱动力的强化学习 [21]，以及”头脑特工队”式的多情感Agent架构，为实现这一目标提供了理论和技术框架。

第四，类人Agent需要”社会智慧”。元认知能力使Agent拥有”自知之明”，心智理论使Agent能够理解他人，情绪智力使Agent能够在社会互动中游刃有余。多智能体逆强化学习 [30] 和嵌套多智能体建模 [29] 等前沿技术，正在为实现这些高阶能力铺平道路。

第五，类人Agent的终极形态是”具身伙伴”。从数字世界走向物理世界，从完成任务走向建立关系，从工具走向陪伴——这是AI Agent发展的长期方向。陪伴机器人和社交机器人的研究，正在探索这一方向的可能性和挑战。

> ***最终愿景**: 我们追求的不是创造一个”完美的人工人类”，而是创造一个能够真正理解我们、陪伴我们、并与我们共同成长的AI伙伴。这个伙伴不需要在每个方面都像人类，但它需要在最重要的方面——理解、共情、适应和成长——展现出类人的品质。从”头脑特工队”式的内部多模块协作，到拥有一个完整”身心”的自主伙伴，我们正处在一个新智能时代的前夜。*

---

10. 参考文献

[1] Jarrahi, M. H. (2018). Artificial intelligence and the future of work: Human-AI symbiosis in organizational decision making. *Business Horizons*, 61(4), 577-586.

[2] Damasio, A. R. (1994). *Descartes' Error: Emotion, Reason, and the Human Brain*. New York: Putnam.

[3] Li, Y., et al. (2025). Scaffolding AI Agents with Hormones and Emotions. *arXiv preprint arXiv:2508.11829v1*.

[4] Iovane, G., Di Pasquale, R. (2025). A Complexity Theory-Based Novel AI Algorithm for Exploring Emotions and Affections by Utilizing Artificial Neurotransmitters. *Electronics* (MDPI).

[5] Iovane, G., Fominska, I., & Di Pasquale, R. (2025). A Neuro-Symbolic Multi-Agent Architecture for Digital Transformation of Psychological Support Systems via Artificial Neurotransmitters and Archetypal Reasoning. *Algorithms* (MDPI).

[6] Mah, A., Golden, C. E. M., & Constantinople, C. M. (2024). Dopamine transients encode reward prediction errors independent of learning rates. *Cell Reports*, 43(3).

[7] Lan, D. C. L., & Browning, M. (2022). What Can Reinforcement Learning Models of Dopamine and Serotonin Tell Us about the Action of Antidepressants? *Computational Psychiatry* (PMC).

[8] Sweller, J. (1988). Cognitive load during problem solving: Effects on learning. *Cognitive Science*, 12(2), 257-285.

[9] Sun, Y., et al. (2023). Interoception and decision-making: A review of the evidence from brain imaging. *Frontiers in Neuroscience*.

[10] Liang, Z., et al. (2025). AI Meets Brain: Memory Systems from Cognitive Neuroscience to Autonomous Agents. *Survey/Review Paper*.

[11] Rolls, E. T. (2024). Generative intelligence in the brain and in machines: Comparison of the human brain and generative AI. *Neuroscience & Biobehavioral Reviews*.

[12] Anthropic. (2025). Effective context engineering for AI agents. *Anthropic Engineering Blog*. https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents

[13] Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative Agents: Interactive Simulacra of Human Behavior. *arXiv preprint arXiv:2304.03442*.

[14] Moscovitch, M., Cabeza, R., Winocur, G., & Nadel, L. (2016). Episodic Memory and Beyond: The Hippocampus and Neocortex in Transformation. *Annual Review of Psychology*, 67, 105-134.

[15] Gutiérrez, B. J., et al. (2024). HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models. *arXiv preprint arXiv:2405.14831*.

[16] Packer, B., et al. (2023). MemGPT: Towards LLMs as Operating Systems. *arXiv preprint arXiv:2310.08560*.

[17] Zheng, Y., et al. (2024). Machine Memory Intelligence: From Biological Inspiration to Computational Implementation. *Research Paper*.

[18] Kahneman, D. (2011). *Thinking, Fast and Slow*. New York: Farrar, Straus and Giroux.

[19] Zhao, H., et al. (2024). Comparing Human Attention and Transformer Attention: A Comparative Study. *Research Paper*.

[20] Picard, R. W. (1995). Affective Computing. *M.I.T. Media Laboratory Perceptual Computing Section Technical Report No. 321*.

[21] Rossi, L. L., et al. (2026). Dual or unified: optimizing drive-based reinforcement learning for cognitive autonomous robots. *Cognitive Systems Research*, 95.

[22] Steunebrink, B. R., Dastani, M., & Meyer, J. J. C. (2009). The OCC Model Revisited. *KI 2009: Advances in Artificial Intelligence*, 32.

[23] Kauvar, I., et al. (2023). AI Agents that “Self-Reflect” Perform Better in Changing Environments (Curious Replay). *Stanford HAI*.

[24] Baars, B. J. (1988). *A Cognitive Theory of Consciousness*. Cambridge University Press.

[25] Flavell, J. H. (1979). Metacognition and cognitive monitoring: A new area of cognitive-developmental inquiry. *American Psychologist*, 34(10), 906-911.

[26] Rota Labs. (2026). When AI Agents Don’t Know What They Don’t Know. *Rota Labs Blog*.

[27] Cuzzolin, F., Morelli, A., Cîrstea, B. C., & Sahakian, B. J. (2020). Knowing me, knowing you: theory of mind in AI. *Psychological Medicine*, 50(7), 1057-1061.

[28] Langley, C., Cirstea, B. I., Cuzzolin, F., & Sahakian, B. J. (2022). Theory of Mind and Preference Learning at the Interface of Cognitive Science, Neuroscience, and AI: A Review. *Frontiers in Artificial Intelligence*, 5, 778852.

[29] Çelikok, M. M., Peltola, T., Daee, P., & Kaski, S. (2019). Interactive AI with a Theory of Mind. *arXiv preprint arXiv:1912.05284*.

[30] Chen, Y., Radulescu, A., & Wu, H. Z. (2024). Unveiling the latent dynamics in social cognition with multi-agent inverse reinforcement learning. *bioRxiv*, 2024-10.

[31] Goleman, D. (1995). *Emotional Intelligence: Why It Can Matter More Than IQ*. New York: Bantam Books.

[32] Shapiro, L. (2019). *Embodied Cognition* (2nd ed.). Routledge.

[33] Breazeal, C. (2003). Toward sociable robots. *Robotics and Autonomous Systems*, 42(3-4), 167-175.

[34] Strickland, E. (2024, May 20). AI Outperforms Humans in Theory of Mind Tests. *IEEE Spectrum*.

[35] Picault, S., & Collinot, A. (1998). Designing social cognition models for multi-agent systems through simulating primate societies. In *Proceedings International Conference on Multi Agent Systems* (pp. 240-247). IEEE.

[36] Lim, S. L., et al. (2025). Affective Computing and Emotion AI: Trends, Challenges, and Opportunities. *Survey Paper*.

[37] Yao, S., et al. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. *ICLR 2023*.

[38] Wei, J., et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *NeurIPS 2022*.

[39] Schick, T., et al. (2023). Toolformer: Language Models Can Teach Themselves to Use Tools. *arXiv preprint arXiv:2302.04761*.

[40] Wang, L., et al. (2024). A Survey on Large Language Model based Autonomous Agents. *Frontiers of Computer Science*.

[41] Xi, Z., et al. (2023). The Rise and Potential of Large Language Model Based Agents: A Survey. *arXiv preprint arXiv:2309.07864*.

[42] Sumers, T. R., et al. (2024). Cognitive Architectures for Language Agents. *arXiv preprint arXiv:2309.02427*.

[43] Weng, L. (2023). LLM Powered Autonomous Agents. *Lil'Log Blog*. https://lilianweng.github.io/posts/2023-06-23-agent/

[44] Shinn, N., et al. (2023). Reflexion: Language Agents with Verbal Reinforcement Learning. *NeurIPS 2023*.

[45] Significant Gravitas. (2023). AutoGPT: An Autonomous GPT-4 Experiment. *GitHub Repository*.

[46] Nakano, R., et al. (2021). WebGPT: Browser-assisted question-answering with human feedback. *arXiv preprint arXiv:2112.09332*.

[47] Deng, X., et al. (2024). Mind2Web: Towards a Generalist Agent for the Web. *NeurIPS 2023*.

[48] Bates, J. (1994). The role of emotion in believable agents. *Communications of the ACM*, 37(7), 122-125.

[49] Reeves, B., & Nass, C. (1996). *The Media Equation: How People Treat Computers, Television, and New Media Like Real People and Places*. Cambridge University Press.

[50] Fong, T., Nourbakhsh, I., & Dautenhahn, K. (2003). A survey of socially interactive robots. *Robotics and Autonomous Systems*, 42(3-4), 143-166.

[51] Dennett, D. C. (1987). *The Intentional Stance*. MIT Press.

[52] Anderson, J. R. (1983). *The Architecture of Cognition*. Harvard University Press.

[53] Newell, A. (1990). *Unified Theories of Cognition*. Harvard University Press.

[54] Laird, J. E. (2012). *The Soar Cognitive Architecture*. MIT Press.

[55] Franklin, S., et al. (2016). LIDA: A Systems-level Architecture for Cognition, Emotion, and Learning. *IEEE Transactions on Autonomous Mental Development*, 8(1), 19-30.

[56] Kotseruba, I., & Tsotsos, J. K. (2020). 40 years of cognitive architectures: core cognitive abilities and practical applications. *Artificial Intelligence Review*, 53, 17-94.

[57] LeCun, Y. (2022). A Path Towards Autonomous Machine Intelligence. *OpenReview Preprint*.

[58] Bengio, Y. (2017). The Consciousness Prior. *arXiv preprint arXiv:1709.08568*.

[59] Lake, B. M., Ullman, T. D., Tenenbaum, J. B., & Gershman, S. J. (2017). Building machines that learn and think like people. *Behavioral and Brain Sciences*, 40, e253.

[60] Hassabis, D., Kumaran, D., Summerfield, C., & Botvinick, M. (2017). Neuroscience-Inspired Artificial Intelligence. *Neuron*, 95(2), 245-258.

[61] Silver, D., et al. (2021). Reward is enough. *Artificial Intelligence*, 299, 103535.

[62] Friston, K. (2010). The free-energy principle: a unified brain theory? *Nature Reviews Neuroscience*, 11(2), 127-138.

---

11. 附录：核心文献索引

A. 按主题分类的核心文献

A.1 生物学启发的Agent架构

文献	核心贡献	关键概念
Li et al. (2025) [3]	人工激素与情感系统	人工皮质醇、多巴胺、催产素
Iovane et al. (2025) [4]	人工神经递质状态空间	7种神经递质、78,125状态、S-E平面
Iovane et al. (2025) [5]	神经符号多Agent架构	NSPA-AI、原型推理、EEG映射
Mah et al. (2024) [6]	多巴胺RPE解耦	RPE与学习率独立编码
Lan & Browning (2022) [7]	多巴胺-血清素双系统	模型无关/依赖RL、时间贴现
Hassabis et al. (2017) [60]	神经科学启发AI	注意力、情景记忆、工作记忆

A.2 记忆系统与认知架构

文献	核心贡献	关键概念
Park et al. (2023) [13]	生成式Agent	记忆流、反思、规划
Packer et al. (2023) [16]	LLM虚拟内存	上下文管理、分层存储
Gutiérrez et al. (2024) [15]	海马体启发RAG	知识图谱索引、多跳推理
Moscovitch et al. (2016) [14]	海马体与记忆转化	图式、记忆巩固、重构
Anthropic (2025) [12]	上下文工程	压缩、笔记、注意力预算
Rolls (2024) [11]	人脑vs机器生成智能	局部关联学习、多记忆系统

A.3 动机、情感与价值观

文献	核心贡献	关键概念
Picard (1995) [20]	情感计算奠基	情感识别、表达、拥有
Rossi et al. (2026) [21]	驱动力强化学习	双系统vs统一系统、内在动机
Steunebrink et al. (2009) [22]	OCC模型修订	认知评估、离散情感
Goleman (1995) [31]	情绪智力	自我意识、共情、社交技能
Bates (1994) [48]	可信Agent中的情感	情感在可信度中的作用

A.4 社会认知与心智理论

文献	核心贡献	关键概念
Cuzzolin et al. (2020) [27]	AI中的ToM	信念建模、意图推断
Langley et al. (2022) [28]	ToM与偏好学习	认知科学-神经科学-AI交叉
Çelikok et al. (2019) [29]	交互式AI与ToM	嵌套多Agent建模
Chen et al. (2024) [30]	社会认知潜在动态	多Agent逆强化学习
Strickland (2024) [34]	AI通过ToM测试	LLM社会推理能力

A.5 认知架构与Agent框架

文献	核心贡献	关键概念
Sumers et al. (2024) [42]	语言Agent认知架构	CoALA框架
Wang et al. (2024) [40]	LLM Agent综述	规划、记忆、工具使用
Xi et al. (2023) [41]	LLM Agent崛起	多Agent协作、社会模拟
Laird (2012) [54]	Soar认知架构	产生式规则、学习机制
Franklin et al. (2016) [55]	LIDA架构	全局工作空间、意识模型
Lake et al. (2017) [59]	像人一样学习和思考	直觉物理、因果推理

A.6 具身智能与陪伴机器人

文献	核心贡献	关键概念
Breazeal (2003) [33]	社交机器人	社会互动设计原则
Fong et al. (2003) [50]	社交机器人综述	互动模式、应用场景
Shapiro (2019) [32]	具身认知	认知接地、情境化
Reeves & Nass (1996) [49]	媒体方程式	人对技术的拟人化反应

B. 三篇例文核心思想提炼

例文一：《Scaffolding AI Agents with Hormones and Emotions》(arXiv:2508.11829) 该论文提出了一个开创性的框架，为AI Agent引入人工激素和情感系统。其核心创新在于将生物学的内分泌调节机制抽象为一个计算模型，使Agent拥有一个持续变化的内部状态。实验证明，配备激素系统的Agent在动态环境中表现出更强的适应性。

例文二：《AI Agents: From Assistants to Autonomous Entities》(arXiv:2601.01885) 该论文系统梳理了AI Agent从简单助手到自主实体的演进路径，重点讨论了Agent的核心能力（感知、推理、规划、行动）和关键挑战（安全、对齐、可扩展性）。它为理解Agent的整体发展脉络提供了宏观视角。

例文三：《The Human-AI Symbiosis Framework》(SSRN-6097646) 该论文提出了一个人机共生框架，强调AI不应取代人类智能，而应与之形成互补。它特别关注了AI在组织决策中的角色，以及如何在人类的直觉判断和AI的分析能力之间取得最优平衡。

本报告由Manus AI Research于2026年3月1日完成。报告中的所有观点和分析均基于公开发表的学术文献和技术文章，旨在为AI Agent的未来发展提供跨学科的理论参考。